

Estudo Guiado

Desafio: Análise Avançada de Dados

Antecipação de Alertas Críticos em Frotas de Mineração

Este estudo guiado orienta o participante pelo fluxo analítico do desafio, desde o entendimento do problema de negócio até a apresentação de resultados. Cada seção define Conteúdos Mínimos (CM X.Y) que devem ser abordados no relatório final. Participantes com maior experiência são encorajados a ir além dos mínimos.

O desafio é aberto: supervisionado, não supervisionado, séries temporais, detecção de anomalias, modelos de sobrevivência, deep learning — qualquer abordagem é válida, desde que justificada. O objetivo é explorar os dados com criatividade e rigor analítico.

Nota: Sempre que uma alteração, exclusão ou decisão metodológica relevante for tomada, registre o ANTES e o DEPOIS com a justificativa correspondente (Controle de Alterações).

1. Entendimento do Negócio (Business Understanding)

Antes de qualquer análise técnica, é fundamental compreender o contexto operacional e traduzir o problema de negócio em uma pergunta analítica clara e mensurável.

Conteúdo Mínimo 1.1 — Contextualização da Operação de Mina

- **Fluxo operacional:** descrever o ciclo de apontamentos — cada registro representa um ciclo de atividade de um equipamento (Início/Fim), com identificação do equipamento (Tag), modelo e frota (Frota), tipo (Caminhão, Carregadeira, etc.), classe da atividade e operador anonimizado.
- **Alertas 'Don't Go':** explicar o que são alertas críticos de condição de equipamento. Um alerta 'don't go' sinaliza que o equipamento não deve operar, com impacto direto em segurança, disponibilidade de frota e produção da mina.
- **Regras de negócio:** referenciar o arquivo Alarmes - SUL_SUDESTE.xlsx como o catálogo de regras que define quando um alerta é disparado — cada linha especifica uma combinação de TIPO + EVENTO + SITUAÇÃO + NÍVEL que constitui um alerta 'don't go'. Este arquivo é equivalente a regras codificadas em Python (thresholds e condições). Listar os eventos de NÍVEL 'Muito Alto' como exemplos de criticidade máxima.

[Figura 1: Diagrama do fluxo operacional: ciclo de apontamento → telemetria → alerta]

Conteúdo Mínimo 1.2 — Definição do Problema Analítico

- **Perguntas analíticas de referência:** o participante deve escolher ao menos uma pergunta de negócio para orientar sua análise. As perguntas abaixo são exemplos validados — o participante pode adaptá-las ou propor outras:
 - Quais equipamentos têm maior risco de gerar um alerta 'don't go' nas próximas 4 horas, considerando o padrão atual de operação?
 - É possível prever o tipo do próximo alerta (ex: transmissão vs. motor) com base nos eventos precedentes?
 - O comportamento do operador (identificado de forma anonimizada) tem correlação com a frequência de alertas em um mesmo equipamento?
 - Qual é o perfil dos equipamentos que geram mais alertas 'don't go' — frota, tipo e horas trabalhadas?
 - Alertas críticos se concentram em determinados turnos, dias da semana ou períodos do mês?
 - Dado o risco previsto de alerta, qual seria a recomendação de ação: continuar operação, manutenção preventiva agendada ou parada imediata?
 - Como priorizar a fila de inspeção da manutenção com base no score de risco de cada equipamento?
- **Métrica de sucesso do negócio:** definir o que significa 'resolver' o problema. Exemplos: % de alertas antecipados, redução de horas de parada não planejada, custo evitado por alerta detectado com antecedência.
- **Cenário de aplicação:** descrever ao menos um cenário concreto de uso do modelo em operação (ex: alerta no sistema de monitoramento do dispatcher com N horas de antecedência).

2. Entendimento dos Dados (Data Understanding / EDA)

A Análise Exploratória de Dados (EDA) é a etapa de investigação inicial. O objetivo é desenvolver familiaridade profunda com os dados antes de qualquer modelagem: entender distribuições, detectar anomalias, identificar padrões e levantar hipóteses.

Conteúdo Mínimo 2.1 — Carregamento e Inspeção Inicial

- Carregar todos os datasets disponíveis e apresentar: shape (linhas × colunas), tipos de dados (dtypes), contagem de valores nulos por coluna e quantidade de registros duplicados.
- Distribuição temporal: identificar a janela de datas cobertas pelos dados, frequência média de registros por dia/hora e equipamento.
- **Estatísticas descritivas:** tabela com min, max, média, mediana e desvio padrão para todas as variáveis numéricas.

Feature	Tipo	% Nulos	Min	Max	Média	Mediana	Desvio Padrão
...	...	...	...	...	...	...	...
...	...	...	...	...	...	...	...
...	...	...	...	...	...	...	...
...	...	...	...	...	...	...	...
...	...	...	...	...	...	...	...

[Figura 2: Distribuição temporal dos registros de apontamentos (volume por dia/hora)]

Conteúdo Mínimo 2.2 — Análise da Variável Alvo

- **Distribuição dos alertas:** após rotular os dados com as regras do Alarmes - SUL_SUDESTE.xlsx, apresentar a distribuição de alertas por TIPO, NÍVEL e Tag de equipamento.
- **Balanceamento de classes:** calcular a proporção de registros com e sem alerta. Classes muito desbalanceadas exigem estratégias específicas — documentar a proporção encontrada.
- **Série temporal de alertas:** visualizar a frequência de ocorrências de alertas ao longo do tempo (por dia, semana ou turno). Identificar sazonalidades ou períodos de concentração.

[Figura 3: Distribuição de alertas por tipo e nível de criticidade]

[Figura 4: Série temporal: frequência de alertas ao longo do período analisado]

Conteúdo Mínimo 2.3 — Análise de Features

- **Correlações:** apresentar heatmap de correlação entre variáveis numéricas. Identificar features com alta correlação entre si (potencial multicolinearidade) e com a variável alvo.
- **Distribuição por categoria:** analisar a distribuição de alertas por Frota, Tipo de equipamento e Classe de atividade. Identificar grupos com maior incidência.
- **Padrões temporais:** investigar variações por hora do dia, dia da semana e turno. Alertas concentrados em determinados períodos podem indicar padrões operacionais relevantes.

Nota: Registrar todas as hipóteses levantadas durante a EDA — mesmo as não confirmadas serão úteis para interpretar os resultados do modelo.

[Figura 5: Heatmap de correlação entre features numéricas]

[Figura 6: Taxa de alertas por hora do dia e dia da semana (heatmap ou barplot)]

3. Preparação dos Dados (Data Preparation)

Dados de telemetria industrial tipicamente apresentam ruídos, inconsistências temporais e necessitam de engenharia de features específica para capturar o comportamento sequencial dos equipamentos. Esta seção documenta todas as transformações aplicadas.

Conteúdo Mínimo 3.1 — Limpeza e Tratamento

- **Missing values:** justificar a estratégia adotada para cada coluna com dados ausentes (remoção de linhas, imputação por mediana/moda, forward-fill para séries temporais, etc.).
- **Inconsistências temporais:** verificar e tratar registros onde Início > Fim, ciclos com duração nula ou negativa, e sobreposições de ciclo para o mesmo equipamento.
- **Outliers:** definir critério de identificação (ex: ± 3 desvios padrão, IQR) e documentar a decisão: remover, imputar ou manter com flag.
- **Controle de alterações:** tabela ANTES/DEPOIS listando todos os registros excluídos ou alterados com justificativa.

Campo	Problema Identificado	Qtd. Registros	Tratamento Aplicado	Justificativa
...	...	...	...	...
...	...	...	...	...
...	...	...	...	...
...	...	...	...	...

Conteúdo Mínimo 3.2 — Engenharia de Features

- **Features temporais:** extrair da coluna Início/Fim — hora do dia, dia da semana, mês, turno (manhã/tarde/noite), duração do ciclo em minutos, dias desde o último alerta do mesmo equipamento.
- **Rolling windows:** para cada equipamento (Tag), calcular agregações nas últimas N horas ou M ciclos anteriores: contagem de alertas, duração média de ciclo, frequência de determinadas classes de atividade.
- **Encoding categórico:** converter Tag, Frota, Tipo, Classe e Operador em representações numéricas — justificar a escolha (one-hot, label encoding, target encoding, frequency encoding) com base na cardinalidade e no modelo alvo.
- **Features derivadas das regras de negócio:** criar features que reflitam a proximidade do estado atual do equipamento com as condições de alerta definidas no Alarmes - SUL_SUDESTE.xlsx (ex: contagem de pré-condições atendidas nas últimas N horas).

***Nota:** Documentar cada feature criada: nome, fórmula de cálculo e motivação. Features não óbvias devem ter a hipótese que as motivou explicitada.*

Feature	Descrição	Fórmula / Lógica	Motivação
...	...	...	...
...	...	...	...
...	...	...	...
...	...	...	...

...	...	...	...
...	...	...	...

Conteúdo Mínimo 3.3 — Definição da Variável Alvo

- **Rotulação via regras de negócio:** aplicar as condições do arquivo Alarmes - SUL_SUDESTE.xlsx sobre os dados de telemetria para identificar eventos que constituem alertas 'don't go'. Um registro é positivo se satisfaz a combinação TIPO + EVENTO + SITUACAO + NIVEL de ao menos uma linha do catálogo de regras.
- **Estratégia de construção do target:** apresentar e justificar ao menos uma das abordagens:
 - Classificação binária: flag 1/0 indicando se, nas próximas X horas/ciclos do equipamento, ocorrerá um alerta crítico.
 - Regressão: valor contínuo representando o tempo (em horas ou ciclos) até o próximo alerta do equipamento.
 - Label de anomalia: para abordagens não supervisionadas, usar os alertas como ground truth de validação, sem usá-los no treinamento.
- **Janela de predição:** justificar a janela de antecipação escolhida (ex: 4 horas, 8 horas, próximo turno) com base no contexto operacional e no tempo necessário para ação corretiva.

[Figura 7: Diagrama da janela de predição: instante de decisão → janela → evento alvo]

4. Modelagem — Mundo Aberto (Modeling)

Esta seção é intencionalmente aberta. Não existe uma única abordagem correta para este desafio. O participante é encorajado a explorar, combinar e criar — o rigor na justificativa das escolhas vale tanto quanto a sofisticação técnica.

Os itens a seguir representam caminhos possíveis, não obrigatórios individualmente. A exigência mínima é: documentar ao menos duas abordagens distintas, com baseline definido.

Conteúdo Mínimo 4.1 — Estratégia de Validação

- **Dimensão temporal:** dados de série temporal não devem ser divididos aleatoriamente — o conjunto de validação/teste deve ser sempre posterior ao de treino no eixo do tempo (ex: TimeSeriesSplit, walk-forward validation, hold-out temporal).
- **Justificativa:** explicar por que a validação cruzada k-fold padrão pode introduzir data leakage em dados temporais e como a estratégia escolhida evita esse problema.
- **Proporção do split:** documentar as proporções utilizadas (ex: 70% treino / 15% validação / 15% teste) e as datas de corte.

[Figura 8: Diagrama da estratégia de validação temporal (treino / validação / teste)]

Conteúdo Mínimo 4.2 — Baseline

- **Modelo de referência:** implementar ao menos um modelo simples como referência de comparação. Exemplos: regra heurística baseada em frequência histórica de alertas por equipamento, modelo dummy (predict majority class), média móvel de alertas.
- Apresentar as métricas do baseline — qualquer modelo proposto deve superar esta referência para ser considerado útil.

Conteúdo Mínimo 4.3 — Modelagem Principal

- Explorar e documentar ao menos duas abordagens distintas entre as categorias abaixo (ou outras de escolha do participante):
- **Supervisionadas — Classificação:** Random Forest, XGBoost, LightGBM, Regressão Logística, SVM, Redes Neurais (MLP). Prever se um alerta ocorrerá na janela de predição definida.
- **Supervisionadas — Regressão / Sobrevivência:** Gradient Boosting Regressor, modelos de sobrevivência (Cox Proportional Hazards, Weibull AFT). Prever o tempo até o próximo alerta.
- **Não Supervisionadas — Clustering:** K-Means, DBSCAN, Hierarchical Clustering. Identificar perfis de comportamento de equipamentos e associar clusters a maior/menor incidência de alertas.
- **Não Supervisionadas — Detecção de Anomalias:** Isolation Forest, One-Class SVM, Autoencoder (LSTM ou variacional). Detectar desvios do padrão normal de operação como sinal precursor de alerta.
- **Séries Temporais:** ARIMA, Prophet, LSTM, Transformer. Modelar a frequência de alertas como série temporal e prever períodos de alta incidência.
- **Abordagens Combinadas / Avançadas:** Stacking ou blending de modelos heterogêneos, modelos generativos para data augmentation de alertas raros (SMOTE, CTGAN), Graph Neural Networks para relacionamentos entre equipamentos.

Para cada abordagem explorada, documentar: escolha de hiperparâmetros e estratégia de tuning (grid search, random search, Optuna/Bayesian optimization), decisões de pré-processamento específicas ao modelo, e justificativa da escolha da abordagem em relação ao problema.

Nota: *Quantidade não é qualidade. Dois modelos bem justificados e analisados em profundidade valem mais do que cinco modelos descritos superficialmente.*

5. Avaliação (Evaluation)

A avaliação conecta o desempenho técnico dos modelos ao impacto de negócio. Métricas devem ser escolhidas em função das consequências reais de cada tipo de erro.

Conteúdo Mínimo 5.1 — Seleção e Justificativa de Métricas

- **Contexto de desbalanceamento:** alertas críticos tendem a ser eventos raros. Accuracy pode ser enganosa — priorizar Recall, Precision, F1-Score e AUC-ROC como métricas primárias para problemas de classificação.
- **Custo assimétrico dos erros:** discutir o impacto operacional de falso negativo (alerta não detectado → parada não planejada) vs. falso positivo (alerta falso → parada desnecessária). Justificar o ponto de operação escolhido na curva Precision-Recall.
- **Tabela comparativa de modelos:** apresentar tabela com as métricas de todos os modelos avaliados no conjunto de validação.

Modelo	Precision	Recall	F1	AUC-ROC	AUC-PR	Observações
...	...	...	...	...	...	...
...	...	...	...	...	...	...
...	...	...	...	...	...	...
...	...	...	...	...	...	...
...	...	...	...	...	...	...

[Figura 9: Curvas ROC e Precision-Recall comparando os modelos avaliados]

Conteúdo Mínimo 5.2 — Análise de Erros

- **Matriz de confusão:** apresentar e comentar a matriz de confusão do modelo selecionado, traduzindo os números em impacto operacional.
- **Casos extremos:** analisar os falsos negativos mais críticos — quais equipamentos, frotas ou condições o modelo sistematicamente falha em detectar?
- **Degradação temporal:** avaliar se a performance do modelo se mantém estável ao longo do tempo ou se existe drift nos dados (concept drift, data drift).

[Figura 10: Matriz de confusão do modelo selecionado com anotações de impacto operacional]

Conteúdo Mínimo 5.3 — Interpretabilidade

- **Importância de features:** apresentar o ranking de importância das variáveis utilizando SHAP values, permutation importance ou equivalente para o modelo escolhido.
- **Validação de sentido:** discutir se as features mais importantes fazem sentido do ponto de vista operacional. Features que o modelo considera importantes mas que não têm explicação operacional devem ser investigadas.
- **SHAP plots:** para modelos complexos (ensemble, redes neurais), incluir summary plot e ao menos um example plot mostrando a contribuição de cada feature para uma predição específica.

[Figura 11: SHAP summary plot — importância e direção de cada feature]

[Figura 12: SHAP waterfall plot — decomposição de uma predição individual]

6. Resultados, Conclusão e Trabalhos Futuros

Conteúdo Mínimo 6.1 — Resultados e Discussão

- **Comparação com baseline:** apresentar a melhoria de performance do melhor modelo em relação ao baseline definido na seção 4.2. A melhoria deve ser quantificada.
- **Tradução para impacto de negócio:** converter métricas técnicas em impacto estimado. Exemplos: 'Com Recall de X%, o modelo teria antecipado Y% dos alertas críticos no período analisado, representando Z horas de parada evitada.'
- **Insights não óbvios:** destacar descobertas inesperadas ou contra-intuitivas encontradas durante a análise — estes são frequentemente os achados mais valiosos.

[Figura 13: Comparação visual de performance: baseline vs. modelos desenvolvidos]

Conteúdo Mínimo 6.2 — Conclusão

- **Resposta à pergunta analítica:** retomar a pergunta formulada em CM 1.2 e respondê-la objetivamente com base nos resultados obtidos.
- **Limitações:** ser honesto sobre as limitações da abordagem — volume de dados, janela temporal coberta, features não disponíveis, generalização para outras regiões ou frotas.

Conteúdo Mínimo 6.3 — Trabalhos Futuros

- Propor ao menos três extensões concretas e justificadas. Exemplos de categorias:
 - Novos dados: integração de dados de manutenção preventiva, condições climáticas, histórico de falhas mecânicas.
 - Novas features: variáveis derivadas de sensores de telemetria em tempo real, features de comportamento do operador.
 - Abordagens alternativas: modelos online (incremental learning) para adaptar-se a drift, reinforcement learning para política de manutenção.
 - Integração operacional: arquitetura de deploy do modelo no sistema de monitoramento da frota, pipeline de retraining automático.

Referências e Recursos

- Alarmes - SUL_SUDESTE.xlsx — Catálogo de regras de negócio para alertas 'don't go' (pasta business/).
- Dicionario_Dados.xlsx — Descrição das features da tabela Apontamentos.
- Desenvolver_Template.docx — Template de relatório final do desafio.
- Kaggle Learn — Introdução a Machine Learning, Feature Engineering e Explainability (kaggle.com/learn).
- SHAP documentation — shap.readthedocs.io
- scikit-learn documentation — scikit-learn.org
- Lifelines (modelos de sobrevivência) — lifelines.readthedocs.io